

Introducción a la Modulación Digital

Universidad ORT Uruguay

Prof. Fernando Paganini

Versión electrónica elaborada por
Andrés Ferragut y Fabián Kozynski

Revisado en: Agosto 2025

Índice

1. Introducción	2
1.1. Motivación de la transmisión digital	3
1.2. Diagrama general de un sistema de transmisión digital	4
1.3. Conceptos básicos de codificación	5
2. Procesos aleatorios	10
2.1. Proceso estocástico de tiempo discreto	10
2.2. Proceso estocástico de tiempo continuo	13
A. Apéndice	18
A.1. Repaso breve de probabilidad	18

Capítulo 1

Introducción

El objetivo de este curso es analizar las técnicas básicas para la *transmisión digital de datos* sobre un canal imperfecto. Para ello, haremos un fuerte uso de las técnicas de análisis de señales en tiempo discreto y continuo (teoremas de muestreo, Transformada de Fourier, etc.), y las extenderemos para realizar modelos de transmisión adecuados a las señales digitales.

En primer lugar, corresponde definir nuestro objeto de trabajo:

Definición (Señal digital de tiempo discreto). *Una señal digital es una secuencia $\{a_k : k \in \mathbb{Z}\}$ de símbolos, cada uno de ellos perteneciente a un alfabeto finito:*

$$a_k \in \{s_1, \dots, s_M\}$$

siendo M el tamaño del alfabeto.

Cuando $M = 2$, el alfabeto se denomina binario y cada símbolo puede interpretarse como un 0 o un 1, permitiendo así la transmisión básica de la información digital. Sin embargo, como veremos más adelante, puede ser relevante considerar alfabetos de mayor cantidad de símbolos, permitiendo enviar mayor cantidad de “bits por símbolo”, es decir cada símbolo contiene una mayor cantidad de “información”.

Notemos además que los símbolos no son necesariamente 0 y 1. Por ejemplo, para un alfabeto binario veremos que puede ser interesante codificar los símbolos como 1 y -1 en algunas aplicaciones, de manera de obtener señales de valor medio nulo.

El objetivo entonces de un sistema de comunicación digital es transmitir, sobre un canal imperfecto, una señal digital de tiempo discreto y *reconstruir*, a la salida, una señal digital $\{\hat{a}_k\}$ de manera tal de que *maximizar la cantidad de símbolos reconstruidos de manera correcta*. Dicho de otro modo, si el sistema de transmisión, modulación, canal y detección introducen perturbaciones aleatorias, que la probabilidad de *error de símbolo*, $P(a_k \neq \hat{a}_k)$ sea (en régimen) la menor posible.

Como se intuye de la ecuación anterior, aparecen dos conceptos clave a tener en cuenta en el presente curso:

- Es útil trabajar con *señales aleatorias*. Esto es porque no conocemos a priori *qué es lo que se va a transmitir*, y quizás solo propiedades estadísticas de la señal. A su vez, todo canal de comunicación está sujeto a *ruido* que es intrínsecamente aleatorio. Esto requiere familiaridad con el concepto de *proceso estocástico* que definiremos en el Capítulo 2, así como con las reglas básicas de probabilidad, que se recuerdan en el Apéndice A.1.
- Por otra parte, al tratarse de análisis de señales, tanto en tiempo discreto como tiempo continuo, se requiere familiaridad con los conceptos de sistemas lineales invariantes en el tiempo (que servirán para modelar el canal, entre otras cosas), así como la *Transformada de Fourier*, tanto en su versión discreta como continua. En particular veremos cómo las propiedades estadísticas de una señal se relacionan, mediante la transformada de Fourier, con su *densidad espectral de potencia*, concepto que definiremos también en el Capítulo 2.

1.1. Motivación de la transmisión digital

La primera pregunta que debemos contestar es por qué puede ser conveniente transmitir datos de manera digital, esto es, siguiendo un alfabeto finito, en lugar de transmitir o intentar reproducir una forma de onda, como se vio en la modulación analógica. Si bien esta última fue el primer mecanismo masivo de transmisión de datos a larga distancia, y aún se utiliza hoy en múltiples aplicaciones (radio comercial, control de tráfico aéreo, etc.), debemos recordar que el *primer sistema de transmisión eléctrica de datos* corresponde a la telegrafía: esto es, el envío de mensajes sobre un cable de cobre (cable telegráfico). Dichos mensajes correspondían típicamente a mensajes de texto (letras y números), que eran *codificados* como pulsos de distinta duración (cortos y largos). Esto dio lugar al primer ejemplo de código para la transmisión eléctrica: el código Morse (1844, c.f. [telégrafía eléctrica](#)).




Figura 1.1. Telégrafo de Morse.

Para entender las ventajas de la comunicación digital, es bueno remitirse primero a un esquema básico de comunicación analógico, como el mostrado en la Figura 1.2. Allí, la fuente de información (ej. audio) es transformada en una señal eléctrica continua $x(t)$ por un transductor (ej. micrófono). El sistema de modulación intentará transmitir dicha señal por un medio físico, recibiendo $\hat{x}(t)$, señal que luego es enviada a otro transductor (ej. parlante) para enviarla al receptor. El objetivo de este proceso es que la señal $\hat{x}(t)$ reproduzca lo más fielmente posible la señal original $x(t)$, en todo momento del tiempo. Sin embargo, esto resulta imposible debido a que el canal siempre introduce atenuación, limitaciones de ancho de banda, potencia de transmisión y ruido que alteran la recepción (en algunos casos hasta volverla inservible).

En la transmisión digital, se transmiten símbolos a_k construyendo una señal real $x(t)$ que depende de dichos símbolos. Si la señal recibida $\hat{x}(t)$ es suficientemente inteligible, podemos decodificar el símbolo $\hat{a}_k$ con *muy alta probabilidad* de que sea exactamente igual a a_k . En ese caso, la reconstrucción de la señal es perfecta (con alta probabilidad). Es decir, *no hay pérdida de información por atravesar el canal*. Esto vuelve la transmisión mucho más robusta al ruido e interferencia. El objetivo principal de este curso es entender precisamente cómo realizar este proceso.

Complementario a lo anterior existen dos fuertes razones para analizar la transmisión digital de datos:

1. En primer lugar, en los últimos años, casi toda la información se almacena en forma digital (texto, fotos, video). En ese sentido, la información ya se encuentra en un alfabeto de símbolos (ej. binario) y no tiene sentido plantearse pasar por una etapa analógica, salvo para efectivamente transmitir sobre el medio físico.
2. En otros casos, la señal analógica se convierte en una señal digital mediante un conversor analógico/digital (A/D) (Figura 1.3) Aquí se cumplen dos etapas:




Figura 1.2. Diagrama general de un sistema de transmisión analógico.




Figura 1.3. Conversión analógica a digital.

- Se *muestra* la señal a una frecuencia de muestreo f_s (muestras por segundo).
- Se *cuantifica* la señal pasando el valor analógico a una cierta cantidad de símbolos (bits). Por ejemplo, las señales de audio se muestrean a $f_s = 44100\text{Hz}$ y se digitalizan utilizando 16 bits de resolución para cada canal estéreo. El resultado es una secuencia de muestras a_k de $\approx 1,41\text{Mbps}$.

En el segundo caso, por el Teorema de Nyquist del muestreo, sabemos que si la señal $x(t)$ tiene ancho de banda B , entonces obteniendo muestras a frecuencia $f_s > 2B$ es posible reconstruir la señal de manera *exacta* a partir de las muestras $x(kT_s)$ con $T_s = 1/f_s$. Sin embargo, como las muestras están cuantificadas, $a_k \approx x(kT_s)$ pero no es exacto, introduciendo el llamado *ruido de cuantificación*. Este ruido es menor a mayor cantidad de bits utilizados para representar las muestras. Sin embargo, si la transmisión digital permite reconstruir las muestras a_k exactamente, es probable que dicho ruido de cuantificación sea menor que el que introduce un esquema de modulación analógico, por lo cual la señal se recibe de mejor manera. A su vez, con los esquemas de modulación modernos, es posible aprovechar mejor el ancho de banda mandando más información (bits) sobre el mismo, por lo cual podemos realizar transmisiones de calidad.

1.2. Diagrama general de un sistema de transmisión digital

El diagrama general de un sistema de transmisión digital se muestra en la Figura 1.4. Allí partimos de una fuente ya digital que genera símbolos $\{a_k\}$, y se pasa por dos etapas de codificación que explicaremos. Con ello se genera una nueva señal digital $\{b_k\}$ que se enviará por el medio físico. Para ello, se requiere una etapa de *modulación digital*, en la cual los símbolos b_k se convierten en una señal analógica adecuada, se envían por el canal, y luego son reconstruidos por un *detector* digital, que obtiene una secuencia $\hat{b}_k$. El objetivo de esta etapa es lograr que $P(\hat{b}_k = b_k)$ sea máxima, de este modo permitiendo reconstruir la señal. Luego esta se decodifica por el proceso inverso a la codificación para obtener $\hat{a}_k$ y enviar esta señal al receptor.

El objetivo de este curso es analizar la etapa de *modulación digital*, es decir dada una secuencia de símbolos $\{b_k\}$, cómo construir una señal analógica $x(t)$ que contenga la información de dichos símbolos y sea adecuada para su transmisión por el medio físico (radio, par de cobre, fibra óptica). Luego de




Figura 1.4. Diagrama general de un sistema de transmisión digital.

su transmisión, la señal alterada deberá ser detectada y de allí reconstruiremos una secuencia de símbolos con baja probabilidad de error. El término modulación digital hace referencia a que la señal discreta *modula* características de la señal analógica. Notemos además que este proceso requiere un bloque adicional: el *sincronismo*, para que el receptor sepa a qué velocidad se transmite la información y cuál es el mejor momento del tiempo para muestrear la señal $\hat{x}(t)$ de manera de recuperar $\hat{b}_k$.

Si bien en este curso no trabajaremos sobre la etapa de *codificación*, es importante entender el rol que cumplen las mismas previo a la transmisión. Introducimos ahora los principales conceptos.

1.3. Conceptos básicos de codificación

Como se observa en la Figura 1.4, existen dos etapas: la *codificación de fuente* y la *codificación de canal*, con sus respectivos decodificadores.

1.3.1. Codificación de fuente

El objetivo de la codificación de fuente es *eliminar redundancia* de los datos, produciendo una secuencia de símbolos con menor cantidad de “bits por símbolo”, de manera de requerir menor velocidad de transmisión de información. Existen dos tipos:

Codificación sin pérdida: Aquí la secuencia de símbolos generada contiene toda la información de la señal $\{a_k\}$, pero *comprimida*. Esto es, utilizando propiedades estadísticas de la señal, se logra representar la misma información con menos bits. Un ejemplo de esto es el algoritmo [Lempel-Ziv](#), utilizado en la compresión “.zip”.

Codificación con pérdida: Aquí la secuencia de símbolos generada contiene *menos información* que la original, eliminando por ejemplo partes que no son requeridas por el receptor. Ejemplos de esto son la compresión de imágenes JPEG, la compresión de video MPEG y la codificación de audio MP3. En estos casos, la señal reconstruida es una “buena aproximación” de la información original. Qué quiere decir “buena aproximación” depende de la aplicación, pero a modo de ejemplo el MP3 permite reducir la velocidad de audio mencionada anteriormente (1,41Mbps) a 192kbps o menos sin que el usuario detecte mayormente la diferencia.

Ejemplo 1.1 (Codificación sin pérdida). *Consideremos una fuente de datos que genera símbolos indepen-*

dientes con la siguiente estadística:

$$a_k \in \{0, 1, 2, 3\} \text{ con distribución } \begin{cases} P(a_k = 0) = 1/2 \\ P(a_k = 1) = 1/4 \\ P(a_k = 2) = 1/8 \\ P(a_k = 3) = 1/8 \end{cases}$$

En este caso, una codificación sencilla sería tomar el código:

$$\begin{cases} a_k = 0 \mapsto \tilde{a}_k = 00 \\ a_k = 1 \mapsto \tilde{a}_k = 01 \\ a_k = 2 \mapsto \tilde{a}_k = 10 \\ a_k = 3 \mapsto \tilde{a}_k = 11 \end{cases}$$

Observemos que el código anterior requiere en promedio 2 bits por símbolo (ya que todos los códigos son de 2 bits). ¿Podemos hacerlo mejor? Consideremos el siguiente código, debido a [Huffman](#):

$$\begin{cases} a_k = 0 \mapsto \tilde{a}_k = 0 \\ a_k = 1 \mapsto \tilde{a}_k = 10 \\ a_k = 2 \mapsto \tilde{a}_k = 110 \\ a_k = 3 \mapsto \tilde{a}_k = 111 \end{cases}$$

Notemos que el código anterior es un código de prefijo (cada símbolo empieza de manera diferente), lo que permite que sea invertible. Es decir si por ejemplo recibimos:

$$0101001110110111 \mapsto 0\ 10\ 10\ 0\ 111\ 0\ 110\ 111 \mapsto 01103023$$

Calculemos el largo medio de la palabra enviada de la siguiente forma, donde $\ell(\cdot)$ representa el largo del código:

$$\begin{aligned} \bar{L} &= P(a_k = 0)\ell(0) + P(a_k = 1)\ell(10) + P(a_k = 2)\ell(110) + P(a_k = 3)\ell(111) \\ &= \left(\frac{1}{2}\right)(1) + \left(\frac{1}{4}\right)(2) + \left(\frac{1}{8}\right)(3) + \left(\frac{1}{8}\right)(3) = 1,75 < 2 \end{aligned}$$

Esto quiere decir que en el largo plazo, una secuencia de N símbolos podrá ser representada por $\approx 1,75N$ bits (en lugar de $2N$), permitiendo un ahorro.

La clave del ejemplo anterior está en elegir palabras más largas para símbolos menos frecuentes. Notemos que esto mismo ya había sido advertido por Morse en su código, como se ve en la Figura 1.1. Surgen entonces las siguientes preguntas: ¿cuál es el mínimo largo medio posible de codificación? ¿Es alcanzable?

En 1948, [Claude Shannon](#) establece la teoría matemática de transmisión de información, introduciendo el concepto de *entropía* de una fuente. Dicha entropía representa la cantidad de información contenida en una fuente (considerando sus propiedades estadísticas). Para una fuente X que genera símbolos independientes $\{a_k\}$, la misma se define como:

$$H(X) = - \sum_k p_k \log_2(p_k)$$

siendo p_k la probabilidad de cada símbolo y $\log_2$ el logaritmo en base 2, lo que hace que la entropía quede en bits/símbolo.

Calculemos la entropía de la fuente anterior:

$$H(X) = \left(\frac{1}{2}\right)(1) + \left(\frac{1}{4}\right)(2) + \left(\frac{1}{8}\right)(3) + \left(\frac{1}{8}\right)(3) = 1,75.$$

Es decir, recuperamos exactamente el largo medio del código de Huffman anterior.




Figura 1.5. Entropía de una fuente binaria. Notar que el máximo se alcanza para $p = 1/2$, es decir, distribución uniforme.

Ejemplo 1.2 (Fuente binaria). Supongamos que los símbolos son binarios $a_k \in \{0, 1\}$ con $P(a_k = 1) = p = 1 - P(a_k = 0)$ e independientes. En ese caso la entropía queda (como función de p):

$$H(p) = -p \log_2(p) - (1-p) \log_2(1-p), \quad (1.1)$$

cuya gráfica puede verse en la Figura 1.5

El Teorema de Shannon muestra que para una fuente dada, su entropía es la mínima cantidad de bits por símbolo alcanzable:

Teorema 1.1 (Shannon, 1948). Sea una fuente de símbolos $\{a_k\}$ y su entropía H_a . Entonces es posible agrupar los símbolos de a bloques de tamaño N y codificarlos en palabras de L_N bits de manera que el largo medio de palabra cumpla:

$$N H_a \leq \bar{L}_N \leq N H_a + 1$$

Como cada bloque codifica N símbolos, la cantidad de bits por símbolo será entonces:

$$H_a \leq \frac{\bar{L}}{N} \leq H_a + 1/N$$

Además, no existe ningún código que logre mejorar esta cota.

La entropía de una fuente nos entonces da la mínima cantidad de bits por símbolo que podemos utilizar, es decir, el límite de la compresión alcanzable. Si volvemos al Ejemplo 1.1, vemos que precisamente el código de Huffman alcanza la mínima entropía posible, incluso con $N = 1$. Para otras distribuciones puede ser necesario utilizar un largo mayor de bloque para aproximar la entropía.

En el Ejemplo 1.2, vemos que la entropía es máxima e igual a 1 cuando los símbolos son *equiprobables* ($p = 1/2$). En ese caso, debemos utilizar 1 bit por símbolo y la señal es incompresible. Precisamente, el código de Huffman descrito logra que la fuente original genere cantidades equiprobables de 0 y 1, por lo cual no puede comprimirse más.

Si en cambio $p \rightarrow 0$, la fuente tiene secuencias largas de 0, y en ese caso puede ser más eficiente codificar el largo de la cadena de 0s que indicar cada bit por separado. En el caso extremo, solo alcanza 1 bit para toda la cadena ("son todos ceros"). Análogamente, si $p \rightarrow 1$.

1.3.2. Codificación de canal

El objetivo de la codificación de fuente es reducir la cantidad de datos a transmitir a su mínima expresión, eliminando redundancia sin pérdida de información (o en el caso con pérdida, sin distorsión

relevante). La *codificación de canal* va en sentido opuesto: agrega redundancia para anticiparse a posibles errores del canal de transmisión y poder detectarlos y corregirlos. A continuación damos algunos ejemplos.

Ejemplo 1.3 (Bit de paridad). Supongamos una fuente binaria $\{a_k\}$ y formemos bloques de largo N . Al final de cada bloque se agrega un bit $a_N = a_0 \oplus \dots \oplus a_{N-1}$ donde $\oplus$ es la operación XOR. Luego se transmite la palabra $b = (a_0, \dots, a_N)$. El resultado final es que $a_N = 1$ si hay una cantidad impar de 1s en el bloque, o dicho de otro modo, cada bloque b tiene una cantidad par de bits. Esto permite detectar (pero no corregir) errores de 1 bit, con un overhead de $1/N$ bits por símbolo.

Obviamente, si el largo de bloque N es grande, el overhead es mínimo, pero la probabilidad de que haya errores de más de un bit es mayor, por lo cual la elección de N es un compromiso entre ambos efectos.

Ejemplo 1.4 (Código de repetición). Supongamos una fuente binaria $\{a_k\}$ y realicemos el siguiente procedimiento: para cada símbolo a_k formamos un bloque $b = (a_k, a_k, a_k)$. Esto es un código de repetición de largo 3. Observemos que si hay un error de 1 bit, podemos decidir por mayoría si el bloque corresponde a un 0 o a un 1. Por ejemplo $(110) \mapsto 1$ y $(010) \mapsto 0$. Esto permite detectar y corregir errores de 1 bit. Sin embargo, requiere 3 bits por símbolo, lo cual es ineficiente.

Ejemplo 1.5 (Matriz de paridad). Consideremos ahora el siguiente procedimiento para una fuente binaria $\{a_k\}$. Elegimos un número M y formamos bloques de tamaño $N = M^2$ dispuestos en forma de matriz de $M \times M$. Luego se agrega a dicha matriz un bit de paridad para cada fila y cada columna, así como un bit de paridad total. Por ejemplo, si $M = 4$, $N = 16$:

$$(1001000111111011) \mapsto \begin{pmatrix} 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \end{pmatrix} \mapsto \begin{pmatrix} 1 & 0 & 0 & 1 & \vdots & 0 \\ 0 & 0 & 0 & 1 & \vdots & 1 \\ 1 & 1 & 1 & 1 & \vdots & 0 \\ 1 & 0 & 1 & 1 & \vdots & 1 \\ \dots & \dots & \dots & \dots & \dots & \dots \\ 1 & 1 & 0 & 0 & \vdots & 0 \end{pmatrix}$$

Luego se envían los N bits y los $M + 1$ bits de paridad agregados.

Si hay un error de un bit, el mismo se detecta y se corrige porque los errores de paridad indican la fila y columna del error, por ejemplo:

$$\begin{pmatrix} 1 & 0 & 0 & 1 & \vdots & 0 \\ 0 & 0 & 0 & 1 & \vdots & 1 \\ 1 & 1 & 1 & 1 & \vdots & 0 \\ 1 & 0 & 1 & 1 & \vdots & 1 \\ \dots & \dots & \dots & \dots & \dots & \dots \\ 1 & 1 & 0 & 0 & \vdots & 0 \end{pmatrix} \rightsquigarrow \begin{pmatrix} 1 & 0 & 0 & 1 & \vdots & 0 \\ 0 & 0 & \color{red}{1} & 1 & \vdots & \color{red}{1*} \\ 1 & 1 & 1 & 1 & \vdots & 0 \\ 1 & 0 & 1 & 1 & \vdots & 1 \\ \dots & \dots & \dots & \dots & \dots & \dots \\ 1 & 1 & \color{red}{0*} & 0 & \vdots & 0 \end{pmatrix}$$

El código detecta entonces donde ocurrió el error porque la paridad de la fila y la columna no es correcta. Notar que el error también puede ocurrir en la fila o en la columna de paridad. Esto también se detecta y se corrige gracias al bit extra de paridad total.

El resultado es que se envían N bits con una redundancia de $2M + 1 = 2\sqrt{N} + 1$ por lo que en un bloque de $N = 1024$ bits solo se requieren 33 bits extra. El overhead crece más lento que el tamaño de bloque. De todos modos sigue siendo ineficiente y solo permite corregir errores de 1 bit, por lo que si el tamaño de bloque es grande, tenemos el mismo problema que en Ejemplo 1.3.

El punto común de todos los ejemplos anteriores es el siguiente: dado un alfabeto de símbolos (por ejemplo binario), construimos bloques de largo N . Esto permite generar 2^N símbolos posibles. Luego agregamos bits de control, generando palabras de largo $N + r$, y aplicando un código que lleva secuencias de largo N a un *espacio mayor* de largo $N + r$, donde los códigos “válidos” se encuentran *más separados entre sí* (solo hay 2^N palabras válidas de las 2^{N+r} posibles). Cuando ocurre algún error, encontramos una palabra no válida y detectamos el error. Si el código es adecuado, podemos además mapear esa palabra no válida a un símbolo válido “cercano” corrigiendo entonces el error.

A mayor r , más redundancia se agrega, más espacio se genera, y podemos detectar y corregir errores más grandes. Pero por otra parte, el overhead es mayor. Se le denomina *tasa de codificación* (*code rate*) al cociente $N/(N + r)$.

Un ejemplo de código de este tipo son los [Códigos de Hamming](#), en los cuales se elige un tamaño de bloque $N + r = 2^r - 1$ con $r \geq 1$ y se envía un mensaje de largo $N = 2^r - r - 1$ con r bits de redundancia, utilizando una transformación lineal invertible. En ese caso, la tasa de codificación queda:

$$R = 1 - \frac{r}{2^r - 1},$$

es decir, la redundancia es del orden de $\log_2(N) \ll \sqrt{N}$. Sin embargo, si bien es más eficiente que la matriz de paridad, este código solo permite detectar errores de 1 o 2 bits, y corregir errores de un único bit. El tipo más común de código de bloques es el de [Reed–Solomon, 1960](#), una familia de códigos que permite detectar errores de hasta r bits y corregir hasta $\lfloor r/2 \rfloor$ bits, siendo r un parámetro, la cantidad de redundancia deseada. Es además capaz de recuperar errores de “borrado”, donde no es posible decidir si el bit recibido es 0 o 1.

Más recientemente, la aparición de los [códigos convolucionales](#), [Turbo-codes](#) y códigos [Low-Parity-Data-Check](#), se logran tasas de codificación cercanas a 1 con muy baja probabilidad de error.

Capítulo 2

Procesos aleatorios

En el estudio de la transmisión de señales (analógicas o digitales), es necesario diseñar el sistema para transmitir información que, a priori, no es conocida en detalle. Por ejemplo, la señal de voz de la radio AM/FM no se conoce hasta el momento de la transmisión. Lo mismo ocurre en la transmisión digital: típicamente podemos conocer *estadísticamente* como se comportan los datos, pero no exactamente qué es lo que se va a transmitir. Debemos entonces poder diseñar y analizar los sistemas de transmisión para que respondan de manera adecuada a este conjunto posible de señales, de las cuales no conocemos exactamente más que sus propiedades estadísticas.

Es por ello esencial introducir el concepto de *proceso estocástico* o aleatorio, que permite modelar este comportamiento. Comenzaremos en tiempo discreto para luego pasar a tiempo continuo, ya que ambos serán necesarios en el estudio de la modulación digital. Remitimos al apéndice A.1 para un resumen de los conceptos previos requeridos de probabilidad y variables aleatorias.

2.1. Proceso estocástico de tiempo discreto

Comencemos por definir el objeto de trabajo:

Definición 2.1. Un proceso estocástico de tiempo discreto es una sucesión de variables aleatorias $\{a_k : k \in \mathbb{Z}\}$ definidas en un espacio de probabilidad y que toman valores en un conjunto de símbolos $\{s_1, \dots, s_M\}$ (espacio discreto) o valores en $\mathbb{R}$ (espacio continuo).

Observemos que la definición anterior no implica que los símbolos o muestras a_k son independientes entre sí, es decir, pueden tener *correlación* entre ellas. La distribución de un proceso estocástico depende precisamente de cuál es la probabilidad de observar cualquier secuencia de símbolos. En general esto es difícil de calcular por lo que definiremos algunas magnitudes de interés.

Definición 2.2. Se definen la media y varianza del proceso como:

$$\mu_k := E[a_k], \quad \sigma_k^2 := E[(a_k - \mu_k)^2] = E[a_k^2] - \mu_k^2.$$

Por último definimos la potencia del proceso como:

$$P_k := E[a_k^2] = \mu_k^2 + \sigma_k^2.$$

Notar que en principio estas dependen de k , que es el índice de tiempo. Esto es, si la estadística del proceso cambia a lo largo del tiempo, también lo harán estas magnitudes.

Para capturar la dependencia del proceso introducimos la siguiente:

Definición 2.3. Se define la autocorrelación de un proceso $\{a_k\}$ como:

$$R(k_1, k_2) = E[a_{k_1} a_{k_2}]$$

Esta magnitud evalúa cuan “alineados” o “similares” son las muestras del proceso en los tiempos k_1 y k_2 . En particular observemos que $R(k, k) = P_k$.

Sin embargo, todas estas magnitudes dependen del tiempo específico en que miremos. Es aquí que conviene introducir la noción de *proceso estacionario*, que son aquellos procesos estocásticos cuyas propiedades estadísticas son invariantes en el tiempo, es decir la distribución de las observaciones a_k o de las parejas (a_{k_1}, a_{k_2}) no depende de k . En particular:

- $E[a_k] = \mu$, $\text{Var}(a_k) = \sigma^2$ y $P = E[a_k^2]$ deben ser constantes.
- La autocorrelación satisface:

$$R(k_1, k_2) = E[a_{k_1} a_{k_2}] = E[a_0 a_{k_2 - k_1}] = E[a_0 a_l] = R(0, l).$$

Es decir la autocorrelación solo depende de $l = k_2 - k_1$, la distancia en el tiempo entre las observaciones o *lag*.

A los efectos de trabajar con señales y modulación conviene entonces introducir la siguiente clase de procesos.


Definición 2.4 (Proceso WSS de tiempo discreto). *Un proceso estocástico $\{a_k\}$ se dice estacionario en sentido amplio (WSS, wide-sense stationary) si verifica:*

1. $E[a_k] = \mu$ constante.
2. $R(a_{k_1}, a_{k_2}) = R_a[k_2 - k_1]$, siendo $R_a[l]$ una función únicamente del lag l , la distancia entre muestras.

Ejemplo 2.1 (Variables aleatorias independientes). *Si las muestras $\{a_k\}$ son variables aleatorias independientes, de media μ y varianza σ^2 constantes, entonces se verifica la primera condición, y la autocorrelación además verifica:*

$$E[a_k a_{k+l}] = \begin{cases} E[a_k^2] = \mu^2 + \sigma^2 & \text{si } l = 0, \\ E[a_k]E[a_{k+l}] = \mu^2 & \text{si } l \neq 0. \end{cases}$$


Por lo tanto el proceso es WSS con $R_a[l] = \mu^2 + \sigma^2 \delta[l]$, siendo δ la delta de Dirac en tiempo discreto ($\delta[0] = 1$, $\delta[l] = 0$, $l \neq 0$).



Ejemplo 2.2 (Símbolos dependientes). *Consideremos una fuente que genera una secuencia de símbolos $\{a_k\} \in \{-1, 1\}$ con la propiedad de que $P(a_{k+1} = -1 | a_k = 1) = P(a_{k+1} = 1 | a_k = -1) = \alpha$. Aquí α representa la probabilidad de “cambiar de estado”. Si $\alpha \rightarrow 0$ la señal tiene rachas largas de 1 y -1. Si $\alpha \rightarrow 1$ alterna periódicamente.*

Es evidente que, en estado estacionario, por ser el sistema simétrico, $P(a_k = 1) = P(a_k = -1) = 1/2$ por lo que en particular $\mu = E[a_k] = 0$. La autocorrelación $R_a[l]$ puede calcularse por métodos que no veremos aquí y vale:

$$R_a[\tau] = (1 - 2\alpha)^{|\tau|}.$$



Listamos a continuación algunas propiedades de la autocorrelación:

1. $R_a[l] = E[a_k a_{k+l}] = E[a_{k-l} a_k] = R_a[-l]$.
2. $R_a[0] = E[a_k^2] = P$.
3. $|R_a[l]| = |E[a_k a_{k+l}]| \leq \sqrt{E[a_k^2] E[a_{k+l}^2]} = \sqrt{P^2} = P = R_a[0]$.

Es decir, en módulo la autocorrelación es máxima en 0. La desigualdad anterior surge de la desigualdad de Cauchy-Schwarz para variables aleatorias.

La autocorrelación es la expresión temporal de cómo se repite (en promedio) la señal. Es por ello que a los efectos de analizar el filtrado y modulación de señales aleatorias interesa definir una expresión en el dominio de la frecuencia.

Definición 2.5 (Densidad espectral de potencia (tiempo discreto)). *Se define la densidad espectral de potencia de un proceso WSS de tiempo discreto con autocorrelación $R_a(\tau)$ como:*

$$S_a(\varphi) = \sum_{l=-\infty}^{\infty} R_a[l] e^{-j2\pi l \varphi}, \quad (2.1)$$

es decir, la TFTD de la autocorrelación.

Esta función es periódica de período 1 como función de φ . La interpretación de φ es de *frecuencia normalizada*, f/f_s siendo f_s la frecuencia de muestras de la señal. En general analizaremos el comportamiento de $S_a(\varphi)$ para $\varphi \in [-1/2, 1/2]$ (correspondiente al intervalo $[-f_s/2, f_s/2]$ de frecuencias observables),

Al ser S_a la TFTD de R_a , notemos que podemos recuperar la autocorrelación de la densidad espectral como:

$$R_a[l] = \int_{-\frac{1}{2}}^{\frac{1}{2}} S_a(\varphi) e^{j2\pi l \varphi} d\varphi.$$

Algunas propiedades de la densidad espectral de potencia son:

1. $S_a(\varphi)$ es real y positiva.
2. Para señales reales, $S_a(\varphi) = S_a(-\varphi)$ (función par).
- 3.


$$P = R_a[0] = \int_{-\frac{1}{2}}^{\frac{1}{2}} S_a(\varphi) d\varphi$$

Es decir, el área bajo la gráfica de S_a (en un período) es igual a la potencia de la señal. En ese sentido, S_a nos indica *cómo se distribuye la potencia* a lo largo de las frecuencias observables.

Ejemplo 2.3. Para el proceso independiente del Ejemplo 2.1, la densidad espectral de potencia queda:

$$S_a(\varphi) = \sum_{l=-\infty}^{\infty} [\mu^2 + \sigma^2 \delta(k)] e^{-j2\pi \varphi \tau} = \sigma^2 + \mu^2 \sum_{l=-\infty}^{\infty} e^{-j2\pi \varphi \tau} = \sigma^2 + \mu^2 \sum_{l=-\infty}^{\infty} \delta(\varphi - l),$$


donde en el último paso usamos la suma de Poisson.



Ejemplo 2.4. Para la señal aleatoria con símbolos dependientes del Ejemplo 2.2, la densidad espectral de potencia queda:

$$\begin{aligned}
 S_a(\varphi) &= \sum_{\tau=-\infty}^{\infty} (1-2\alpha)^{|\tau|} e^{-j2\pi\varphi\tau} = 1 + \sum_{l=1}^{\infty} [(1-2\alpha)e^{-j2\pi\varphi}]^l + \sum_{l=1}^{\infty} [(1-2\alpha)e^{j2\pi\varphi}]^l \\
 &= 1 + \frac{(1-2\alpha)e^{-j2\pi\varphi}}{1-(1-2\alpha)e^{-j2\pi\varphi}} + \frac{(1-2\alpha)e^{j2\pi\varphi}}{1-(1-2\alpha)e^{j2\pi\varphi}} \\
 &= \frac{2\alpha(1-\alpha)}{1-2\alpha(1-\alpha)-(1-2\alpha)\cos(2\pi\varphi)}.
 \end{aligned}$$

Por ejemplo, para $\alpha = 1/4$ queda:



Por último, introducimos una última noción:

Definición 2.6. Un proceso es ergódico si una realización cualquiera es representativa de la estadística del proceso.

La anterior es una definición informal, pero la idea general es que si promediamos los valores de una traza del proceso, entonces recuperamos los valores medios. En particular:

$$\begin{aligned}
 \langle a \rangle &= \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{k=-N}^N a_k = E[a_k] = \mu, \\
 \langle a^2 \rangle &= \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{k=-N}^N a_k^2 = E[a_k^2] = P, \\
 \langle a_k a_{k+l} \rangle &= \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{k=-N}^N a_k a_{k+l} = E[a_k a_{k+l}] = R_a[l].
 \end{aligned}$$

Es decir, los valores medios de una señal dada suficientemente larga aproximan la esperanza, similar a lo que ocurre en la ley de grandes números. En particular se requiere estacionariedad (porque el límite no depende de k). En este curso asumiremos siempre que los procesos con que trabajamos son WSS y ergódicos.

2.2. Proceso estocástico de tiempo continuo

Generalizamos ahora las definiciones ya vistas al caso de tiempo continuo, lo que nos servirá por ejemplo para modelar señales analógicas que son moduladas por una señal digital, o también el ruido que afecta a un sistema.

Definición 2.7. Un proceso estocástico de tiempo continuo es una función aleatoria $x(t, \omega)$ a valores reales, con ω sorteada en un espacio de probabilidad.




Figura 2.1. Diferentes realizaciones de un proceso estocástico de tiempo continuo

La principal diferencia es que ahora el sorteo en el espacio determina toda una función $x(t)$ para cada posible realización del experimento (valor de ω). En la Figura 2.1 se muestra un ejemplo de esto. En general, denotaremos por $x(t)$ a la señal o proceso aleatorio, sin indicar la dependencia con el espacio de probabilidad subyacente.

Dado un proceso estocástico $x(t)$, podemos definir:

Definición 2.8. Se definen la función media y varianza del proceso como:

$$\mu(t) := E[x(t)], \quad \sigma^2(t) := E[(x(t) - \mu(t))^2] = E[x(t)^2] - \mu(t)^2.$$

Por último definimos la potencia del proceso como:

$$P(t) := E[x(t)^2] = \mu(t)^2 + \sigma(t)^2.$$

Tenemos a su vez el análogo a la autocorrelación de tiempo discreto.

Definición 2.9. Se define la autocorrelación de un proceso estocástico de tiempo continuo $x(t)$ como la función de dos variables:

$$R(s, t) = E[x(s)x(t)].$$

Observemos que $R(t, t) = P(t)$.

Nuevamente, todas las magnitudes anteriores dependen en principio de los momentos del tiempo en que miramos el proceso. Buscamos entonces trabajar con procesos *estacionarios* cuya estadística no cambie con el tiempo.

Definición 2.10 (Proceso WSS de tiempo continuo). Un proceso estocástico $x(t)$ se dice estacionario en sentido amplio (WSS, wide-sense stationary) si verifica:

1. $E[x(t)] = \mu$ constante.
2. $R(s, t) = E[x(s)x(t)] = E[x(0)x(t-s)] = R_x(\tau)$, siendo $R_x(\tau)$ una función únicamente de $\tau = t - s$, el tiempo entre muestras.

Tenemos además los análogos de tiempo continuo de la función de autocorrelación.

1. $R_x(\tau) = E[x(t)x(t-\tau)] = E[x(t+\tau)x(t)] = R_x(-\tau)$, es decir R_x es una función par.
2. $R_x(0) = E[x(t)^2] = P$.
3. $|R_x(\tau)| = |E[x(t)x(t-\tau)]| \leq \sqrt{E[x(t)^2]E[x(t-\tau)^2]} = \sqrt{P^2} = P = R_x(0)$. Nuevamente, el módulo de la autocorrelación es máximo en 0. La desigualdad anterior surge de la desigualdad de Cauchy-Schwarz para variables aleatorias.

Por último, un proceso es además ergódico si cada trayectoria $x(t)$ es representativa de la estadística del proceso, como antes. En particular:

$$\begin{aligned}\langle x \rangle &= \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T x(t) dt = E[x(t)] = \mu, \\ \langle (x - \mu)^2 \rangle &= \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T (x(t) - \mu)^2 dt = E[(x(t) - \mu)^2] = \sigma^2, \\ \langle x^2 \rangle &= \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T x(t)^2 dt = E[x(t)^2] = P, \\ \langle x(t)x(t - \tau) \rangle &= \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T x(t)x(t - \tau) dt = E[x(t)x(t - \tau)] = R_x(\tau).\end{aligned}$$

Es decir, los valores medios de una señal dada suficientemente larga aproximan la esperanza, similar a lo que ocurre en la ley de grandes números. Esto requiere estacionariedad (porque el límite no depende de t). En este curso asumiremos siempre que los procesos con que trabajamos son WSS y ergódicos. En particular, μ^2 representa la potencia de continua de la señal, σ^2 la potencia de “alterna” y P la potencia total.

A continuación algunos ejemplos de procesos estacionarios de tiempo continuo.

Ejemplo 2.5 (Sinusoide de fase aleatoria). *Consideremos el siguiente proceso aleatorio:*

$$x(t) = A \cos(2\pi f_0 t + \theta)$$

con θ aleatorio y distribuido uniformemente en el intervalo $[0, 2\pi]$. Este proceso modela el fenómeno de observar una señal sinusoidal de frecuencia fija f_0 , pero sin referencia a su tiempo de origen, es decir, no conocemos la fase del oscilador que la genera. Calculemos:

$$\begin{aligned}E[x(t)] &= E[A \cos(2\pi f_0 t + \theta)] = \int_0^{2\pi} A \cos(2\pi f_0 t + \theta) \frac{1}{2\pi} d\theta \\ &= \frac{A}{2\pi} \int_0^{2\pi} A \cos(2\pi f_0 t + \theta) d\theta = 0.\end{aligned}$$

Notar que estamos integrando en θ , por lo que la integral es en un período de la función cos. Entonces $E[x(t)] = \mu = 0$ constante. Calculemos la autocorrelación:

$$\begin{aligned}E[x(s)x(t)] &= E[A \cos(2\pi f_0 s + \theta) A \cos(2\pi f_0 t + \theta)] = A^2 \int_0^{2\pi} \cos(2\pi f_0 s + \theta) \cos(2\pi f_0 t + \theta) \frac{1}{2\pi} d\theta \\ &= \frac{A^2}{2} \int_0^{2\pi} [\cos(2\pi f_0(t - s)) + \cos(2\pi f_0(t + s) + 2\theta)] \frac{1}{2\pi} d\theta \\ &= \frac{A^2}{2} \left[\cos(2\pi f_0(t - s)) \overbrace{\int_0^{2\pi} \frac{1}{2\pi} d\theta}^{=1} + \overbrace{\int_0^{2\pi} \cos(2\pi f_0(t + s) + 2\theta) \frac{1}{2\pi} d\theta}^{=0} \right] \\ &= \frac{A^2}{2} \cos(2\pi f_0(t - s)) = R_x(\tau).\end{aligned}$$

Por lo tanto el proceso es WSS, ya que la media es constante y la autocorrelación R_x solo depende de la distancia entre muestras. La potencia del proceso $R_x(0) = A^2/2$, que corresponde al valor RMS de una sinusoide de amplitud A .




Figura 2.2. Pulso base y realización de una onda binaria aleatoria del Ejemplo 2.6.

Algunas observaciones importantes sobre el ejemplo anterior: en primer lugar, la autocorrelación es periódica de período $T_0 = 1/f_0$, la frecuencia base. Esto es porque la señal se repite exactamente igual cada tiempo T_0 (de hecho, la autocorrelación vuelve a ser máxima en $f = kf_0$). En segundo lugar, notar que la autocorrelación no lleva información de fase. Por ejemplo, si el Ejemplo 2.5 cambiamos cos por sin, la autocorrelación *no cambia*.¹

Ejemplo 2.6 (Onda binaria aleatoria). *En este ejemplo, consideramos una señal aleatoria de tipo onda cuadrada, pero cuyas amplitudes están controladas por símbolos binarios $a_k = \pm 1$ equiprobables. Este es nuestro primer ejemplo de modulación digital.*

Más concretamente, consideremos el proceso estocástico:

$$x(t) = \sum_{k=-\infty}^{\infty} a_k p(t - kT_s + D),$$

siendo:

- a_k una secuencia de símbolos independientes con $P(a_k = 1) = P(a_k = -1)$.
- $p(t)$ el pulso de alto 1 y duración T_s , el tiempo de símbolo.
- D una v.a. independiente de las anteriores, y con distribución Uniforme en $[0, T_s]$.

Nuevamente aquí D juega el rol de una “fase aleatoria”, en el sentido de que no sabemos cuándo la señal comenzó a transmitir y la observamos en un momento aleatorio del tiempo, como se ve en la Figura 2.2. Sin este paso, el proceso no sería estacionario, ya que los momentos de cambio de símbolo kT_s serían “especiales”.

Calculemos media y autocorrelación de este proceso. Comenzamos por la media: para ello condicionamos a un valor de $D = z$ y luego integramos entre todos los posibles valores de esta variable uniforme, quedando:

$$E[x(t)] = \int_0^{T_s} E[x(t) | D = z] \frac{1}{T_s} dz.$$

Ahora, dado $D = z$, observemos que:

$$p(t - kT_s + z) = 1 \Leftrightarrow 0 \leq t - kT_s + z < T_s \Leftrightarrow k \leq \frac{t+z}{T_s} < k+1.$$

Es decir, existe un único $k = k_0 = \left\lfloor \frac{t+z}{T_s} \right\rfloor$ tal que $p(t - k_0 T_s + z) = 1$. Básicamente esto ocurre porque los pulsos no se solapan y por lo tanto en cada momento del tiempo t observamos un único símbolo a_k . Entonces:

$$E[x(t) | D = z] = P(a_{k_0} = 1)(1) + P(a_{k_0} = -1)(-1) = \frac{1}{2} - \frac{1}{2} = 0,$$

de donde $\mu = E[x(t)] = 0$ para todo t , es decir la señal tiene media constante y no tiene componente de continua.

Pasemos ahora a calcular la correlación $R(t_1, t_2) = E[x(t_1)x(t_2)]$. Distinguimos dos casos:

¹Notar que $\sin(\tau)$ no puede ser una función de autocorrelación adecuada, ya que vale 0 en $\tau = 0$ y es impar.

1. Si $|t_1 - t_2| > T_s$, entonces los símbolos observados en t_1 y t_2 son independientes, ya que pertenecen a pulsos distintos. Es decir, existen $k_1 \neq k_2$ como antes, tales que $p(t_1 - k_1 T_s + z) = 1$ y $p(t_2 - k_2 T_s + z) = 1$. En ese caso:

$$E[x(t_1)x(t_2) | D = z] = E[a_{k_1} a_{k_2}] = E[a_{k_1}] E[a_{k_2}] = 0,$$

es decir no hay correlación para $|t_2 - t_1| \geq T_s$, a distancia más de un tiempo de símbolo.

2. Si en cambio $|t_2 - t_1| < T_s$, entonces los símbolos pueden corresponder al mismo pulso, o a pulsos consecutivos, dependiendo de la fase. Supongamos primero que $t_2 > t_1$ y que $x(t_1) = a_k$. La observación crucial es que el tiempo de cambio de símbolo T_{k+1} tiene distribución uniforme en $[t_1, t_1 + T_s]$, por lo que:

$$\begin{cases} x(t_1) = x(t_2) = a_k & \text{Si } t_2 - t_1 < T_{k+1}, \\ x(t_1) = a_k, x(t_2) = a_{k+1} & \text{Si } t_2 - t_1 \geq T_{k+1}. \end{cases}$$


Por lo tanto:

$$\begin{aligned} E[x(t_1)x(t_2)] &= \overbrace{E[a_k^2]}^{=1} P(T_{k+1} > t_2 - t_1) + \overbrace{E[a_k a_{k+1}]}^{=0} P(T_{k+1} \leq t_2 - t_1) \\ &= 1 - \frac{(t_2 - t_1)}{T_s}. \end{aligned}$$

Un razonamiento análogo para $t_2 < t_1$ permite concluir que el proceso es WSS (la autocorrelación solo depende de $\tau = t_2 - t_1$) y su función de autocorrelación es:

$$R_x(\tau) = 1 - \frac{|\tau|}{T_s} \quad -T_s \leq \tau \leq T_s, \quad (2.2)$$

y 0 en otro caso.



Definición 2.11 (Proceso Gaussiano).

Definición 2.12 (Ruido blanco Gaussiano (WGN)).

Apéndice A

Apéndice


A.1. Repaso breve de probabilidad

La teoría de probabilidades se basa en postular un espacio abstracto Ω en el que se “sortea” un elemento ω . Se asigna una probabilidad $P(A) \in [0, 1]$ a ciertos subconjuntos $A \subset \Omega$, llamados “sucesos”.

Si lo aleatorio es un número real, podríamos tomar $\Omega = \mathbb{R}$, pero en general se piensa en el sorteo como algo que está “detrás” determina el valor $X(\omega)$ a través de una función $X : \Omega \rightarrow \mathbb{R}$, llamada *variable aleatoria* (V.A.)


La función de distribución de una V.A. se define como $F_X(x) = P(X \leq x)$

$F_X(x)$ está entre 0 y 1, es monótona creciente y continua a la derecha.





Ejemplo A.1. *Variable aleatoria discreta.*

X toma sólo los valores $\{x_1, \dots, x_N\}$.



Cada salto es $p_i = P(X = x_i)$.

Ejemplo A.2. *Variable aleatoria absolutamente continua, $\exists f_X(x) = \frac{d}{dx} F_X(x)$ densidad.*



$$P(a < X \leq b) = F_X(b) - F_X(a) = \int_a^b f_X(x) dx.$$

Nota: Se puede definir una densidad para las V.A. discretas si se aceptan en ella δ 's de Dirac. Es decir, en este caso

$$f_X(x) = \sum_i p_i \delta(x - x_i).$$

Esta convención se adopta en lo que sigue.

Valor esperado de una variable aleatoria

$$E[X] = \int_{-\infty}^{\infty} x f_X(x) dx.$$

Representa el promedio ponderado por la probabilidad. Notar que en el caso de las V.A. discretas, lo anterior equivale a $E[X] = \sum_i x_i p_i$.

Momento de orden k

$$E[X^k] = \int_{-\infty}^{\infty} x^k f_X(x) dx.$$

Varianza: $\text{Var}[X] = E[X^2] - E[X]^2$.

Ejemplo A.3. V.A. Gaussiana,

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}; \quad E[X] = \mu, \quad \text{Var}[X] = \sigma^2.$$

Distribución conjunta de n variables aleatorias $X_1, X_2, \dots, X_n$:

$$F_{X_1, \dots, X_n}(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n).$$

Independencia

- 2 sucesos $A, B \subset \Omega$ son independientes si $P(A \cap B) = P(A)P(B)$.
- 2 V.A. X, Y , son independientes si los sucesos $\{X \leq x\}, \{Y \leq y\}$ son independientes, es decir

$$F_{XY}(x, y) = F_X(x)F_Y(y).$$

Propiedad: Si X, Y independientes $\Rightarrow E[XY] = E[X]E[Y]$.

Este valor esperado también es una forma de *correlación*. Si $X(\omega)$ e $Y(\omega)$ se “acompañan”, $E[XY]$ da grande. $\langle X, Y \rangle = E[XY]$ es un producto interno entre V.A. de $E[X^2]$ finito.

La *covarianza* de 2 V.A. se define como $E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$. Si X, Y independientes, entonces $\text{Cov}(X, Y) = 0$. Se dice que están no correlacionadas. El recíproco no vale en general, sí para V.A. Gaussianas.